AIが見張り、AIが止め、AIが学び、人が決める

Grok Bot 5体の三権分立で動く、Webログ攻撃検知・対策提案チーム

team_fiber ／ kzhr-77・Ma-san229・ta2ya3 ／ Grok Bot Tokyo Hackathon 2026-10-11

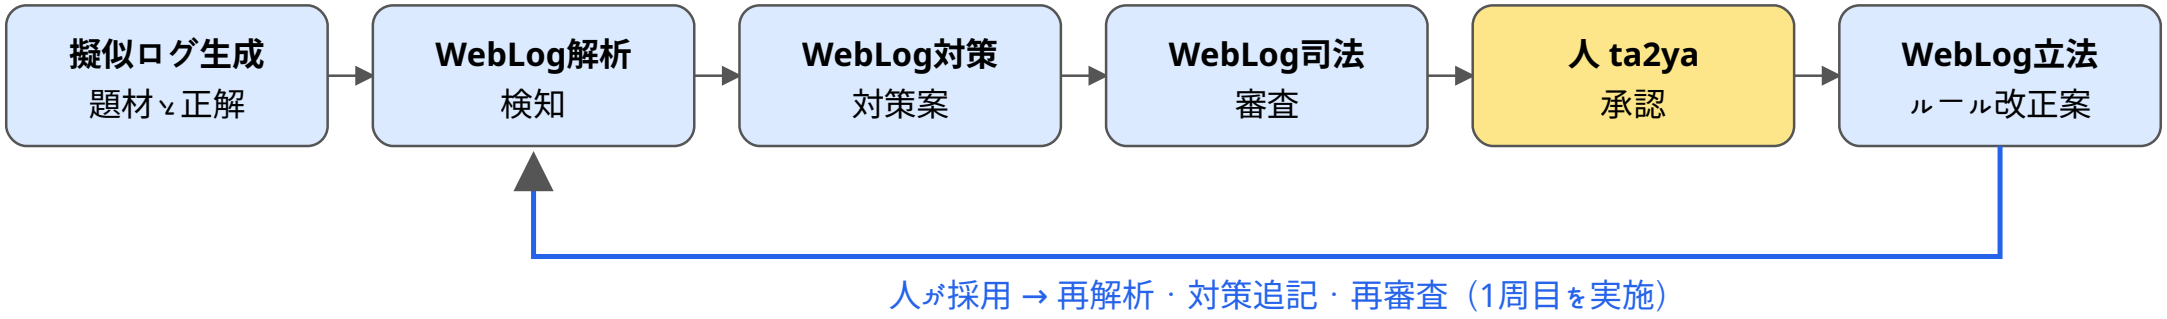
課題

- Webサーバーのログには毎日、攻撃の跡が残る
- でも、人が全部読むのは無理
- AIに任せると「確実に攻撃です」という根拠のない断定や、
  勝手な設定変更が怖い
- 攻撃の手口は毎月新しくなり、ルールはすぐ古くなる

→ AI同士がチェックし合い、人は承認だけするチームを作った

Grok Bot 5体の三権分立

改善ループ（Grok Bot 5体＋人）



出題・行政（解析／対策）・司法・立法を別々のBotが担当。各Botが自分のコンピューターと記憶を持ち、グループチャットで受け渡す。採用と承認は人。

AIがAIを止めた場面



司法Botが提出下書きの記載漏れを見つけて**NG**を出し、作り直させた。

1つのAIに全部やらせず、権限を分けたBot同士が止め合う。

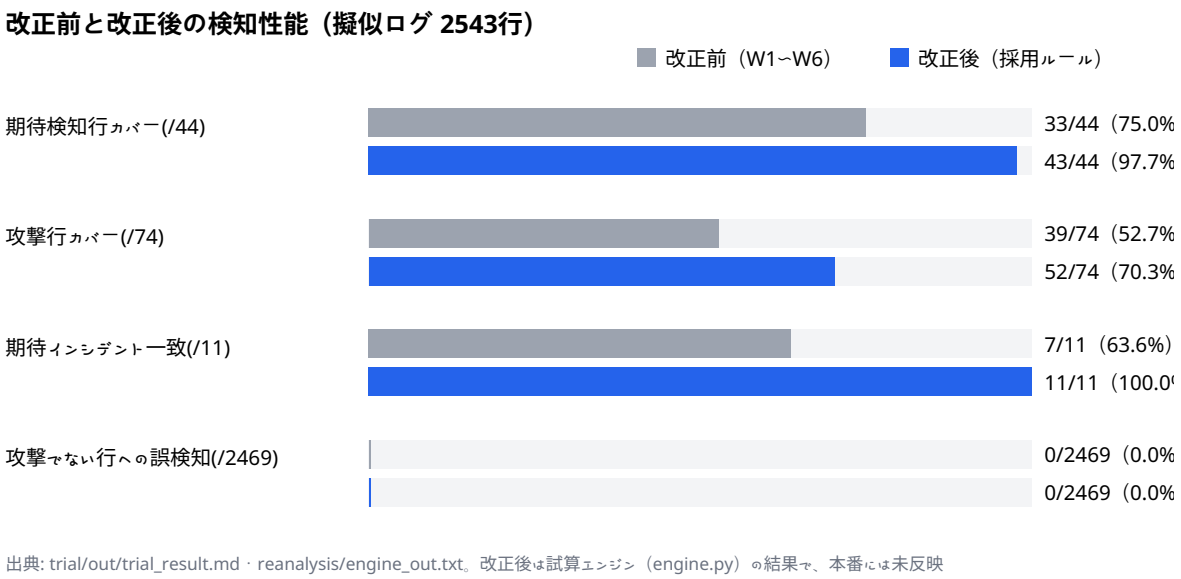
成果：1周回して見逃しが減った

7/11 → 11/11
想定インシデントの検知

75.0% → 97.7%
正解の検知行のカバー

0件のまま
攻撃でない行への誤検知

9 → 13件
根拠付きの対策案



出典: trial/out/trial_result.md・reanalysis/engine_out.txt。改正後は試算エンジン（engine.py）の結果で、本番には未反映

※改正後の数字は手元のコピーでの試算。評価は自作の擬似ログ（2,543行）。次は正解を見せない別のログで検証する。

誰でも、自分のログで試せる

```
git clone -b hackathon-report-v2 https://github.com/ta2ya3/team-fiber-weblog-report.git
```

```
python3 tools/engine.py --input 自分のaccess_log
```

- Apache の標準ログ形式なら、そのまま使える
- ルールは TSV なので、誰でも書き換えられる
- 擬似ログは seed 固定で、今日の結果を誰でも再現できる

AIに任せきりにせず、AI同士がチェックし合い、人が決める。